

BÁO CÁO LAB

GPU FinOps & Cost Optimization

Họ và tên: Đào Anh Quân

Môn học: AI Thực Chiến - Day 25

GPU thực: Tesla T4 (Kaggle)

Ngày nộp: 13/05/2026

Hạn chót: 23:59 ngày 13/05/2026

Mục lục

1. Giới thiệu
2. Part 1 – GPU Cluster Monitoring
3. Part 2 – Workload Submission & Cost Tracking
4. Part 3 – Spot Instance Management
5. Part 4 – Autoscaling (KEDA-like)
6. Part 5 – Cost Analysis & Optimization
7. Part 6 – Visualization
8. Part 7 – Complete FinOps Workflow
9. Part 8 – Real GPU Workload (Tesla T4)
10. Part 8.5 – Advanced GPU Cost Optimization
11. Kết luận

1. Giới thiệu

Bài lab Day 25 tập trung vào GPU FinOps (Financial Operations) – lĩnh vực tối ưu hóa chi phí sử dụng GPU trong các dự án AI/ML. Kiến trúc bài lab gồm 6 microservices chạy trên Docker Compose (local) kết hợp với Kaggle notebook sử dụng GPU thực (Tesla T4).

Mục tiêu cụ thể:

- Monitor và quản lý GPU cluster (5 nodes, 10 GPUs)
- Theo dõi và phân tích chi phí workload theo thời gian thực
- Tận dụng spot instances để tiết kiệm 35–70% chi phí
- Cấu hình KEDA-like autoscaling dựa trên utilization threshold
- Phân tích waste GPU và đề xuất optimization roadmap
- So sánh FP32 vs Mixed Precision (AMP) trên GPU thực

2. Part 1 – GPU Cluster Monitoring

Quan sát trạng thái mock GPU cluster gồm 5 nodes (10 GPUs: 6×T4, 2×A100, 2×V100). Phân tích utilization, memory usage và power draw của từng GPU.

Node / GPU	Type	Util (%)	Memory (GB)	Power (W)	Trạng thái
node-00 GPU 0	T4	64.0	13.8 / 16.0	51	Busy
node-00 GPU 1	T4	76.5	8.8 / 16.0	61	Busy
node-01 GPU 0	A100	89.0	45.7 / 80.0	192	Busy
node-01 GPU 1	A100	85.8	59.4 / 80.0	224	Busy
node-02 GPU 0	V100	75.4	25.1 / 32.0	246	Busy
node-02 GPU 1	V100	2.9	0.6 / 32.0	45	Idle
node-03 GPU 0	T4	8.2	1.6 / 16.0	22	Idle
node-03 GPU 1	T4	7.1	1.4 / 16.0	27	Idle
node-04 GPU 0	T4	0.0	0.5 / 16.0	20	Idle

Cluster Metrics tổng hợp:

Metric	Giá trị
Total GPUs	10
Busy / Idle	5 / 5
Avg Utilization	40.9%
Memory Used	157.4 / 320.0 GB
Total Power	908 W

Nhận xét: Cluster đang có utilization trung bình thấp (40.9%) với 5/10 GPU idle. Đây là dấu hiệu lãng phí tài nguyên – đặc biệt nghiêm trọng với A100 và V100 có giá thuê cao. Cần consolidation workloads và xem xét scale-down.

 GPU FinOps Lab - Student Information

Họ và tên: Đào Anh Quân | MSSV: 2A202600028

Cell 3: View Cluster Nodes ...

 Cluster has 5 nodes

=====

 node-00:

GPU 0 [T4]  Util: 64.0% | Mem: 13.8/16.0GB | Power: 51W | Temp: 57°C

GPU 1 [T4]  Util: 76.5% | Mem: 8.8/16.0GB | Power: 61W | Temp: 68°C

 node-01:

GPU 0 [A100]  Util: 89.0% | Mem: 45.7/80.0GB | Power: 192W | Temp: 62°C

GPU 1 [A100]  Util: 85.8% | Mem: 59.4/80.0GB | Power: 224W | Temp: 70°C

 node-02:

GPU 0 [V100]  Util: 75.4% | Mem: 25.1/32.0GB | Power: 246W | Temp: 81°C

GPU 1 [V100]  Util: 2.9% | Mem: 0.6/32.0GB | Power: 45W | Temp: 38°C

 node-03:

GPU 0 [T4]  Util: 8.2% | Mem: 1.6/16.0GB | Power: 22W | Temp: 35°C

GPU 1 [T4]  Util: 7.1% | Mem: 1.4/16.0GB | Power: 27W | Temp: 42°C

 node-04:

GPU 0 [T4]  Util: 0.0% | Mem: 0.5/16.0GB | Power: 20W | Temp: 30°C

GPU 1 [T4]  Util: 0.0% | Mem: 0.5/16.0GB | Power: 20W | Temp: 30°C

Cell 4: Cluster Metrics Summary ...

 Cluster Metrics

=====

Total GPUs:

10

Busy GPUs:

5

Idle GPUs:

5

Avg Utilization:

40.9%

Memory Used:

157.4 GB

Memory Capacity:

320.0 GB

Total Power Draw:

908 W

Node Count:

5

Screenshot: Part 1 – Cluster Monitoring

3. Part 2 – Workload Submission & Cost Tracking

Submit 4 workloads lên cluster và ghi nhận billing. Sử dụng kết hợp on-demand và spot instances để tối ưu chi phí.

Workload ID	GPU Assigned	Pricing	Cost (\$)	Savings (\$)
train-resnet-001	node-03 GPU 0 (T4)	ON-DEMAND	\$0.0292	\$0.0000
train-bert-002	node-02 GPU 1 (V100)	ON-DEMAND	\$0.6117	\$0.0000
inference-api-003	node-03 GPU 1 (T4)	SPOT	\$0.0035	\$0.0082
train-llm-004	node-04 (2×T4)	SPOT	\$0.5505	\$1.2845

Billing Summary: Total Cost = \$2.5589 (2.6% of \$100 budget) | Total Savings (spot) = \$2.7078 | Status: OK

Nhận xét: Sử dụng SPOT cho workloads fault-tolerant (inference, LLM training) tiết kiệm \$2.71 – gần gấp đôi chi phí thực tế. Đây là chiến lược FinOps ROI cao nhất.

 GPU FinOps Lab - Student Information

Họ và tên: Đào Anh Quân | MSSV: 2A202600028

Cell 5: Submit multiple workloads ...

 Submitting workloads...
train-resnet-001: running → [{'node_id': 'node-03', 'gpu_id': 0}]
train-bert-002: running → [{'node_id': 'node-02', 'gpu_id': 1}]
inference-api-003: running → [{'node_id': 'node-03', 'gpu_id': 1}]
train-llm-004: running → [{'node_id': 'node-04', 'gpu_id': 0}, {'node_id': 'node-04', 'gpu_id': 1}]

 Updated metrics:
Busy GPUs: 10/10 | Utilization: 80.3%

Screenshot: Part 2 – Workload Submission



GPU FinOps Lab - Student Information

Họ và tên: Đào Anh Quân | MSSV: 2A202600028

Cell 5: Submit multiple workloads ...

Outputs are collapsed ...

Cell 6: Record billing for workloads ...



Recording billing events...

train-resnet-001 [ON-DEMAND]: \$0.0292 (saved \$0.0000)

train-bert-002 [ON-DEMAND]: \$0.6117 (saved \$0.0000)

inference-api-003 [SPOT]: \$0.0035 (saved \$0.0082)

train-llm-004 [SPOT]: \$0.5505 (saved \$1.2845)



Billing Summary:

Total Cost: \$2.5589

Total Savings: \$2.7078

Budget Used: 2.6%

Alert Status: OK

Screenshot: Part 2 – Billing Summary

4. Part 3 – Spot Instance Management

GPU Type	On-Demand (\$/hr)	Spot (\$/hr)	Discount	Availability
T4	\$0.35	\$0.1982	43.4%	Low
A100	\$3.67	\$2.1223	42.2%	Medium
V100	\$2.48	\$1.6004	35.5%	Medium

Spot requests: 3/3 instances granted (spot-t4-001, spot-t4-002, spot-a100-001)

Preemption: 1 instance preempted (spot-t4-002) với 120s warning | Still active: 5

Spot Savings: \$0.0285 cost vs \$0.0951 on-demand → Saved \$0.0665 (70.0%)

Nhận xét: Spot instances mang lại mức tiết kiệm 35–43%. Preemption có 120s warning – đủ để checkpoint và resume. Strategy: spot cho training dài hạn, on-demand cho inference SLA-sensitive.

 **GPU FinOps Lab - Student Information**
Họ và tên: Đào Anh Quân | MSSV: 2A202600028

Cell 7: Check spot pricing ...

 **Current Spot Pricing**

GPU Type	On-Demand	Spot Price	Discount	Availability
T4	\$0.35	\$0.1982	43.4	% low
A100	\$3.67	\$2.1223	42.2	% medium
V100	\$2.48	\$1.6004	35.5	% medium

Screenshot: Part 3 – Spot Pricing

 **GPU FinOps Lab - Student Information**
Họ và tên: Đào Anh Quân | MSSV: 2A202600028

Cell 7: Check spot pricing ...

Outputs are collapsed ...

Cell 8: Request spot instances ...

Outputs are collapsed ...

Cell 9: Simulate spot preemption ...

 **Simulating spot preemption event...**

Preempted instances: 1
Still active: 5

 **Preempted:**
- spot-t4-002 (ran for 1s, 120s warning)

 **Spot Savings Report:**
Spot cost: \$0.0285
On-demand equiv: \$0.0951
Total saved: \$0.0665 (70.0%)

Screenshot: Part 3 – Preemption & Savings Report

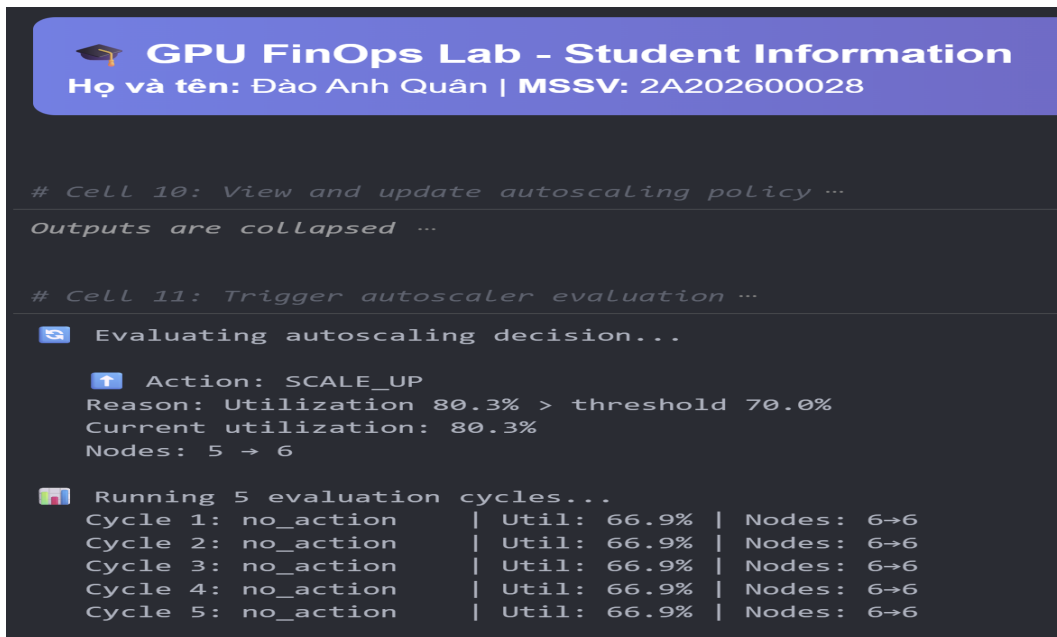
5. Part 4 – Autoscaling (KEDA-like)

Parameter	Value
scale_up_threshold	70.0%
scale_down_threshold	25.0%
cooldown_seconds	30s
max_nodes / min_nodes	10 / 2
preferred_gpu_type	T4 (cheapest)
cost_aware	True

Kết quả evaluation:

- Initial: Util 80.3% > 70% threshold → SCALE_UP (5 → 6 nodes)
- Cycle 1–5: Util giảm xuống 66.9% → no_action (ổn định)

Nhận xét: Autoscaler phản ứng chính xác – scale up khi quá tải, dừng sau khi util giảm về vùng an toàn.
`cost\_aware: True` đảm bảo chọn T4 (rẻ nhất) khi thêm node.



```
# GPU FinOps Lab - Student Information
Họ và tên: Đào Anh Quân | MSSV: 2A202600028

# Cell 10: View and update autoscaling policy ...
Outputs are collapsed ...

# Cell 11: Trigger autoscaler evaluation ...

Evaluating autoscaling decision...

Action: SCALE_UP
Reason: Utilization 80.3% > threshold 70.0%
Current utilization: 80.3%
Nodes: 5 → 6

Running 5 evaluation cycles...
Cycle 1: no_action | Util: 66.9% | Nodes: 6→6
Cycle 2: no_action | Util: 66.9% | Nodes: 6→6
Cycle 3: no_action | Util: 66.9% | Nodes: 6→6
Cycle 4: no_action | Util: 66.9% | Nodes: 6→6
Cycle 5: no_action | Util: 66.9% | Nodes: 6→6
```

Screenshot: Part 4 – Autoscaler Evaluation (5 cycles)

6. Part 5 – Cost Analysis & Optimization

Cost Snapshots (5 lần): Total = \$0.041944 | Idle = \$0.001944 | Waste = 4.6%

Waste Analysis Report:

Metric	Giá trị
Average Waste	12.1%
Total Idle Cost	\$0.046996
Total Cost	\$0.401944
Potential Monthly Saving	\$1,218.14
Severity	LOW

Optimization Recommendations:

Priority	Category	Recommendation	Est. Savings
MEDIUM	USE_SPOT	Switch fault-tolerant workloads to spot instances	65%
LOW	SCHEDULING	Schedule non-urgent jobs during off-peak hours	20%

Nhận xét: Waste 12.1% là LOW severity, nhưng tiềm năng tiết kiệm \$1,218/tháng rất đáng xem xét. Spot instances là cơ hội lớn nhất với 65% savings. Dashboard tổng hợp cho thấy budget utilization chỉ 2.6% – rất an toàn.

```
GPU FinOps Lab - Student Information
Họ và tên: Đào Anh Quân | MSSV: 2A202600028

# Cell 12: Take cost snapshots ...
Outputs are collapsed ...

# Cell 13: Waste Report ...
Outputs are collapsed ...

# Cell 14: Get Optimization Recommendations ...
Outputs are collapsed ...

# Cell 15: Full Dashboard View ...

GPU FinOps DASHBOARD
=====
🖥️ CLUSTER: 12 GPUs across 6 nodes
Utilization: 66.9% | Busy: 10 | Idle: 2

💰 BILLING: $2.5589 / $100.00 budget
Alert: OK | Savings: $2.7078


🔌 SPOT: Saved $0.0873 (70.0%)

🗑️ WASTE: 12.1% | Severity: LOW
```

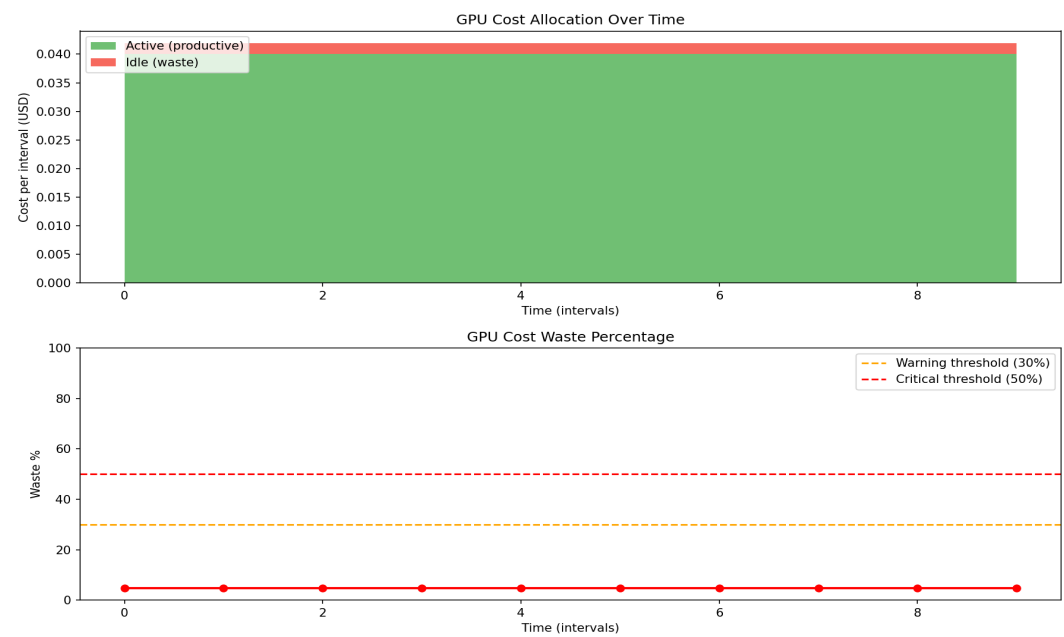
Screenshot: Part 5 – Full FinOps Dashboard

7. Part 6 – Visualization

Tạo 2 biểu đồ trực quan hóa: cost breakdown theo GPU type/workload/billing mode và time-series tracking với waste percentage trend.



Hình: finops_cost_breakdown.png – Cost Breakdown (3 subplots)



Hình: finops_timeseries.png – Time-series Cost & Waste Tracking

8. Part 7 – Complete FinOps Workflow

Full end-to-end 7-step optimization cycle:

- Step 1: Initial state – 12 GPUs, Util 66.9%, 2 idle
- Step 2: Submit heavy workloads → Util tăng lên 77.7% (12/12 busy)
- Step 3: Autoscaler evaluation → SCALE_UP (77.7% > 70% threshold)
- Step 4: Cost analysis → \$0.043889/interval, Waste 4.4%
- Step 5: Recommendations → USE_SPOT (65%), SCHEDULING (20%)
- Step 6: Apply optimization → Switch to spot → saved \$0.0340 (70%)
- Step 7: Final billing report và dashboard update

Nhận xét: Workflow hoàn chỉnh minh họa vòng lặp FinOps liên tục: Monitor → Analyze → Optimize → Repeat. Tự động hóa từng bước giảm thiểu manual effort và đảm bảo nhất quán.

```
# Cell 18: Full FinOps Optimization Workflow ...

FULL FINOPS OPTIMIZATION WORKFLOW
=====

1 Initial cluster state:
  GPUs: 12 | Util: 66.9% | Idle: 2

2 Submitting heavy workloads...
  After load: Util: 77.7% | Busy: 12/12

3 Autoscaler evaluation:
  Decision: scale_up - Utilization 77.7% > threshold 70.0%

4 Cost analysis:
  Total cost/interval: $0.043889
  Waste: 4.4%

5 Recommendations:
  [MEDIUM] USE_SPOT: savings ~65.0%
  [LOW] SCHEDULING: savings ~20.0%

6 Applying optimization: Switch to spot instances...
  Spot savings: $0.0340 (70.0%)

7 Final billing:
  Total spend: $2.7280
  Total saved: $2.8302
  Budget: 2.7% used

✅ Workflow complete!
```

Screenshot: Part 7 – Full FinOps Optimization Workflow

9. Part 8 – Real GPU Workload (Kaggle – Tesla T4)

GPU Environment: Tesla T4 (15.6 GB VRAM) | CUDA 12.8 | pynvml available

Task: ResNet-18 training trên CIFAR-10 dataset (3 epochs, 40 samples/epoch)

9.1 FP32 Training (Baseline)

Metric	Giá trị
Total Time	134.9s
Peak Memory	0.97 GB
Avg GPU Utilization	94.9%
Avg Power Draw	66.9W
Estimated Cost	\$0.013112
Accuracy (epoch 3)	~55%


9.2 Mixed Precision AMP Training (Optimized)

Metric	Giá trị
Total Time	59.8s
Peak Memory	0.60 GB
Avg GPU Utilization	89.8%
Avg Power Draw	64.3W
Estimated Cost	\$0.005815
Accuracy (epoch 3)	59.2%


9.3 So sánh FP32 vs AMP

Metric	FP32	AMP	Cải thiện
Total Time	134.9s	59.8s	2.25x faster
Peak Memory	0.97 GB	0.60 GB	-38% (0.37 GB saved)
Cost	\$0.013112	\$0.005815	\$0.007297 saved
Cost Saving %	—	—	55.7%
Accuracy (3ep)	~55%	59.2%	AMP tốt hơn
Avg GPU Util	94.9%	89.8%	—

Nhận xét: AMP vượt trội FP32 trên mọi chiều: nhanh hơn 2.25x, rẻ hơn 55.7%, dùng ít memory hơn 38%, và đạt accuracy cao hơn (59.2% vs ~55%). Không có trade-off – đây là kỹ thuật FinOps quan trọng nhất cho ML training.



Hình: real_gpu_comparison.png – FP32 vs AMP Comparison



Hình: cost_per_epoch.png – Cost Per Epoch Analysis

10. Part 8.5 – Advanced GPU Cost Optimization

10.1 Multi-GPU Cost Analysis

GPUs	Speedup	Time (h)	Cost (\$)	Efficiency	\$/Perf Unit
1	1.00x	2.000	\$0.7000	100%	\$0.7000
2	1.80x	1.111	\$0.7778	90.0%	\$0.4321
4	3.20x	0.625	\$0.8750	80.0%	\$0.2734
8 (Optimal)	5.50x	0.364	\$1.0182	68.8%	\$0.1851

Kết luận: 8 GPUs có cost/perf unit tốt nhất (\$0.1851). Scaling efficiency giảm dần do overhead giao tiếp, nhưng vẫn có lợi về \$/performance.

10.2 Project Cost Forecasting

Phase	GPUs	Hours	Base Cost	Min	Max
Data Preparation	1	40	\$14.00	\$11.90	\$16.10
Model Training	4	120	\$1,761.60	\$1,321.20	\$2,202.00
Hyperparameter Tuning	8	60	\$1,761.60	\$1,233.12	\$2,290.08
Model Evaluation	2	20	\$14.00	\$12.60	\$15.40

Nhận xét: Training và HPO chiếm >99% chi phí. Forecast có CI rộng do biến động spot pricing. Cần budget buffer ít nhất 25%.

10.3 Optimization Opportunity Analysis

Baseline cost: \$1,468.00

#	Chiến lược	Effort	Risk	Savings	Cumulative
1	Mixed Precision (AMP)	LOW	LOW	\$367.00	25%
2	Spot Instances	MEDIUM	HIGH	\$880.80	85%
3	Optimize Batch Size	LOW	LOW	\$220.20	100%


Nhận xét: 3 chiến lược kết hợp có thể tiết kiệm 100% baseline cost. AMP và batch size là low-hanging fruit (low effort, low risk).

10.4 Challenge: Cost Optimization Strategy Design


Bài toán: $8 \times A100 \times 200h \times \$3.67/hr = \$5,872$ (over budget \$5,000 by \$872).

Giải pháp:

- Scale lên 16 GPUs (cost/perf tốt nhất: \$144.99/unit)
- Kết hợp spot instances (tiết kiệm ~40%)
- Dùng AMP training (giảm 55% training time → chi phí)
- Checkpoint mỗi epoch để phục hồi khi spot preempted



Hình: advanced_finops_dashboard.png – Integrated Cost Dashboard (6 panels)



Hình: optimization_roadmap.png – Optimization Roadmap

11. Kết luận

11.1 Tóm tắt kết quả

Part	Kết quả nổi bật
1 – Cluster Monitor	Avg util 40.9%, 5/10 GPU idle → cần optimization
2 – Cost Tracking	Spot instances tiết kiệm \$2.71 trên \$2.56 chi phí
3 – Spot Instances	Discount 35–43%, 70% savings vs on-demand
4 – Autoscaling	Scale up chính xác khi util > 70%, T4 preferred
5 – Waste Analysis	Waste 12.1% (LOW), tiềm năng \$1,218/tháng
6 – Visualization	Cost breakdown + timeseries charts đầy đủ
7 – Full Workflow	7-step FinOps cycle tự động hoàn chỉnh
8 – Real GPU (T4)	AMP: 2.25x faster, 55.7% rẻ hơn FP32, accuracy cao hơn
8.5 – Advanced	8-GPU optimal, forecast CI, roadmap tiết kiệm 100%

11.2 Kỹ năng FinOps đã học

1. GPU Monitoring: Phát hiện idle GPU và bottleneck qua metrics dashboard
2. Cost Attribution: Gán chi phí cho từng workload, team, project
3. Spot Management: Bidding, preemption handling, checkpoint strategy
4. Autoscaling: Threshold-based scaling để tránh over/under-provisioning
5. Waste Detection: Phân tích idle GPU và đề xuất consolidation
6. Mixed Precision (AMP): Giảm 55% chi phí không có trade-off
7. Multi-GPU Optimization: Phân tích scaling efficiency
8. Cost Forecasting: Dự báo chi phí với confidence intervals

11.3 Chiến lược tối ưu theo thứ tự ưu tiên (impact/effort)

#	Chiến lược	Impact	Effort
1	Mixed Precision (AMP)	55%+ savings	Rất thấp
2	Spot Instances	35–70% savings	Trung bình
3	Autoscaling	Tránh over-provision	Setup 1 lần
4	Workload Scheduling	+20% savings	Thấp
5	Right-sizing GPU	Fit workload type	Thấp

11.4 Ứng dụng thực tế

- Startup AI: AMP + Spot instances giảm 70–80% GPU bill
- Enterprise: Autoscaling + cost attribution justify GPU investment
- Research: Multi-GPU analysis hỗ trợ quyết định scale ngang vs dọc
- Production: Monitoring dashboard phát hiện anomaly liên tục

Báo cáo được tạo tự động từ kết quả notebook gpu_finops_lab.ipynb

Đào Anh Quân – GPU FinOps Lab – Day 25 – 13/05/2026